

*IODAA - De l'InfOrmation à la Décision par l'Analyse et
l'Apprentissage*

Projet Fil Rouge - Rendu final

**Dynamique des cirsés dans le paysage
agricole et périurbain**

Auteurs :

Joseph Allyndrée
Norat Picaut
Amine Kabeche
Delpierot Augustin

Encadrant :

Adrienne Ressayre
Technicien :
Guillaume Poussou
Rodolphe Hugard

github : https://github.com/J-ally/PFR_Cirsés_2022

February 24, 2023

Contents

1	Introduction	2
2	Besoin de l'INRAE et problématique	2
3	Pistes explorées	3
3.1	Etat de l'art	3
3.2	Approche par méthodes d'analyse d'image "classiques"	4
3.3	Découpage des images	5
3.4	Annotation manuelle des imagettes	6
3.5	Modèle de machine learning pour la classification des images : CNN . .	8
3.5.1	Architecture choisie : ResNet	8
3.5.2	Les différentes versions	8
3.5.3	Stratégies d'apprentissages	9
3.6	Le clustering pour l'identification des cirsés issus d'une reproduction clonale ou sexuelle	10
4	Résultats	10
4.1	Développement de l'approche par réseau de neurone à convolution . . .	10
4.1.1	Resnet18 sur les images brutes, excess green et squelettisées sans data augmentation	11
4.1.2	Interprétabilité du modèle	11
4.1.3	Augmentation des données	12
4.1.4	Resnet18 sur les images brutes, excess green et squelettisées avec data augmentation	13
4.1.5	Combinaison des prédictions des 3 modèles	14
4.1.6	Inférence	15
5	Limites de l'approche et perspectives	15
6	Annexe	17
7	Bibliographie	18

1 Introduction

Les cires sont des plantes herbacées, bisannuelles ou vivaces, appartenant à la famille des Astéracées (ou Composées) et au genre *Cirsium*. *Cirsium arvense*, connu sous le nom de Chardon des champs ou Cirse des champs, est une espèce très commune en Europe. C'est une adventice de la plupart des cultures et des prairies. Il se multiplie rapidement par ses nombreuses graines qui, grâce à leurs aigrettes, peuvent être disséminées à grande distance.

Les cires sont donc capables de deux types de reproduction différentes :

- La reproduction sexuée, qui implique le mélange des chromosomes d'un mâle et d'une femelle pour former un nouvel individu qui est une combinaison des caractéristiques héritées des parents. Cette reproduction engendre les graines qui seront ensuite disséminées de différentes manières : transportées par les animaux (zoochorie), par le vent (anémochorie), et enfin une dissémination par l'eau est également possible (hydrochorie).
- La reproduction asexuée est aussi appelée reproduction végétative. Ce type de reproduction implique l'absence de mélange de chromosomes venant des parents et l'individu produit est génétiquement identique au seul individu parent (on parle alors de clone). Cette multiplication végétative se passe pour le cirse par les racines. On en observe ainsi deux types principaux : des racines ligneuses et verticales, mais également horizontales et profondes (50 à 100 cm de profondeur). Cette profondeur rend impossible un simple traitement par labour (labour allant seulement à une profondeur de 30cm).

Cette facilité à la reproduction et la difficulté de traitement le rend problématique pour les cultures. C'est ainsi la 3ème espèce la plus nuisible sur 24 pays européens, seule espèce résistante à 4 herbicides différents.

Notre projet se place donc au sein d'un projet déjà existant de compréhension de la dynamique des cires, comportant des approches multi sites et multidisciplinaires pour comprendre le fonctionnement de la métapopulation à l'échelle des paysages agricoles et évaluer l'impact des mesures de gestion

2 Besoin de l'INRAE et problématique

Pour mieux comprendre la dynamique des cires, des études de génétique des populations, associées à des analyses spatiales ont été lancées. Ces études ont plusieurs buts distincts: mesurer les proportions de multiplication végétative et de reproduction sexuée, étudier les liens entre habitats, évaluer l'impact des pratiques agricoles et de gestion vis-à-vis du cirse.

Ce projet concerne trois sites de l'INRAE : Dijon, Epoisse et Saclay. Chacun des ces sites dispose de parcelles d'essais avec des assolements différents (moutarde, colza, blé, maïs, etc.). Sur certaines de ces parcelles, la présence de cires a été observée à plus ou moins forte intensité (notamment les parcelles où les intrants chimiques ont été fortement réduits).

La problématique est donc de savoir comment détecter dans les différentes zones touchées et l'intensité de l'invasion par ces adventices sur ces zones ; et quelle est leur cinétique de propagation à l'échelle de l'ensemble des parcelles considérées.

3 Pistes explorées

3.1 Etat de l'art

L'approche choisie pour traiter ce problème de détection des cirsées à partir de l'image d'un champ est inspirée des travaux de Rasmussen et al (2019) et celui de A. Sørensen et al (2017). Rasmussen et al. cherchent à détecter des cirsées à partir de photos de drones de champs de blé d'hiver et d'orge de printemps. Ils développent ainsi un outil semi-automatique appelé Thistle Tool basé exclusivement sur la discrimination des couleurs (les adventices, majoritairement des cirsées, apparaissent en vert et les cultures au stade pré-récolte donc sénecentes sont de couleur paille). Les images sont divisées en patchs de 1 m² quelle que soit l'altitude de vol et sont données en entrée de l'outil, qui réalise les étapes suivantes :

- Calcul de l'indice d'excès de vert noté ExG_{x,y}, (Excess green) pour chaque coordonnée de pixel (x, y) de l'image. Cet indice représente l'intensité du vert de chaque pixel, il est déterminé en calculant, pour chaque pixel (2G-R-B) avec G l'intensité de vert du pixel, R l'intensité de rouge, B l'intensité de bleu.
- Calcul d'un classifieur : la TopMaxExG, utilisé pour faire le seuillage
 - Calcul de la TopMaxExG, c'est à dire valeur moyenne des p% de valeurs ExG les plus élevées dans chaque patch, p étant un paramètre. Si p=5 (valeur prise par défaut), alors les 5% des valeurs de ExG les plus élevées dans le patch seront utilisées pour calculer la valeur moyenne TopMaxExG du patch en question
 - Seuillage des patchs, c'est à dire séparation des objets d'intérêts (cirsées) du fond (culture et/ou terre). Le seuil de segmentation t est déterminé manuellement.
- Les patchs sont finalement classés en deux catégories: avec ou sans végétation verte.

Cette approche permet d'obtenir 92 à 97% de bonne classifications sur les images de vol allant de 10 à 50 m d'altitude. Ils observent que la hauteur de vol a peu d'impact sur l'accuracy. Toutefois le seuil de segmentation t (utilisé lors du seuillage des patchs) varie d'une campagne de vol à l'autre. Bien que performante, cette approche n'est pas totalement automatique et n'est pas utilisable lorsque la culture est encore à un stade immature.

Dans leur article datant de 2017, A. Sørensen et al cherchent à améliorer Thistle Tool en utilisant un réseau de neurones à convolution. L'objectif étant de pouvoir détecter les structures et les détails caractéristiques des patchs avec adventices. Le réseau

utilisé est un DenseNet, un réseau à convolution possédant une architecture de type résiduelle. En donnant en entrée au modèle une imagette il renvoie la valeur associée à sa classe prédictive, et en lui donnant une grande image il renvoie un vecteur correspondant à probabilité d'appartenance à une des classes de chaque imagette qui compose la grande image.

Ils obtiennent d'aussi bonnes performances que Thistle Tool sur les deux types de cultures séparément ainsi que sur de l'orge d'hiver, mais de meilleures performances sur les cultures combinées avec des images prises à 10m d'altitude. Les images prises à plus haute altitude sont de plus faibles résolution et donc plus difficiles à annoter correctement.

3.2 Approche par méthodes d'analyse d'image “classiques”

En nous inspirant du workflow de Thistle Tool, la première étape fut d'essayer d'isoler la verdure dans une photo du drone. Pour cela nous utilisons la métrique ExG (Excess Green) évoquée ci-dessus, qui nous donne les résultats suivants :

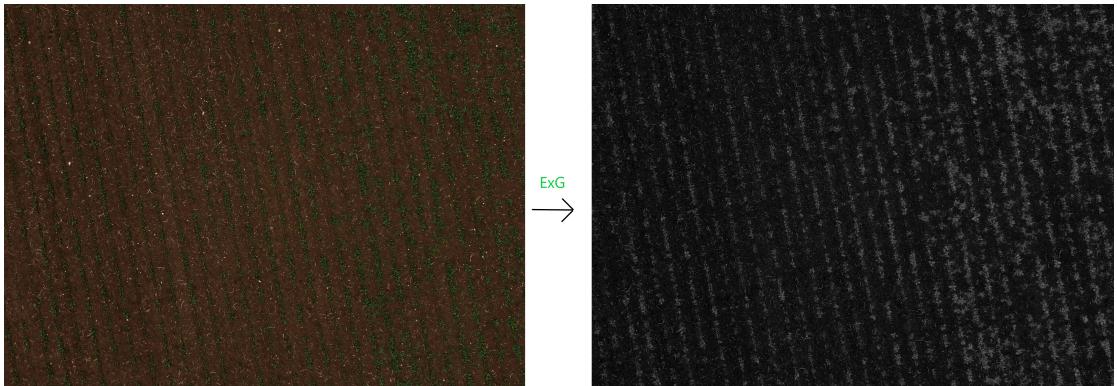


Figure 1: Passage de l'image d'origine à une image avec l'indice de végétation ExG.

Nous observons que la méthode ExG est très robuste pour détecter la verdure dans une photographie. Cependant nous cherchons à identifier les cires en particulier. A l'inverse de Thistle Tool qui utilisait des images de champs de blé jaunes, notre plante d'intérêt (la moutarde ici) a la même couleur (verte) que les cires. Ainsi, une sélection sur simple seuillage (cf. Figure 2) est insuffisante car elle sélectionne aussi les plants de moutarde.

Nous devons donc essayer de repérer la forme caractéristiques des cires. Pour cela nous avons tout d'abord essayé des méthodes de squelettisation. La squelettisation est un procédé consistant à réduire chaque forme d'une image binarisée (comme la figure 2) à son squelette, i.e. une structure fine d'un pixel et équidistante des bords de la forme. Cela permet d'analyser les formes des objets. Npus obtenons le résultat suivant (cf. Figure 3).

Nous pouvons voir que la forme caractéristique en étoile des cires est mise en valeur dans l'image squelettisée. Cependant nous n'avons pas trouvé une façon automatique et robuste de pouvoir repérer cette forme pour l'instant. Nous avons essayé d'autres méthodes, comme convertir une forme de cirse en filtre de convolution pour

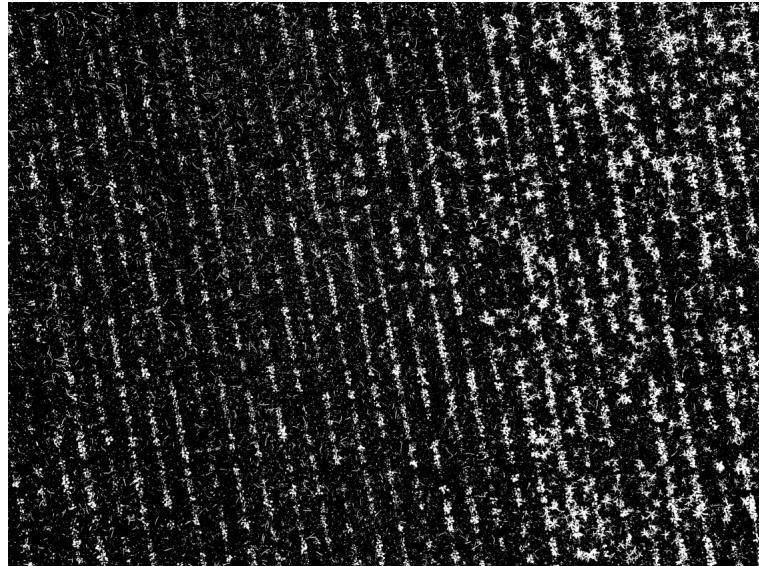


Figure 2: Résultat du seuillage de l'image en ExG par la méthode de Yen

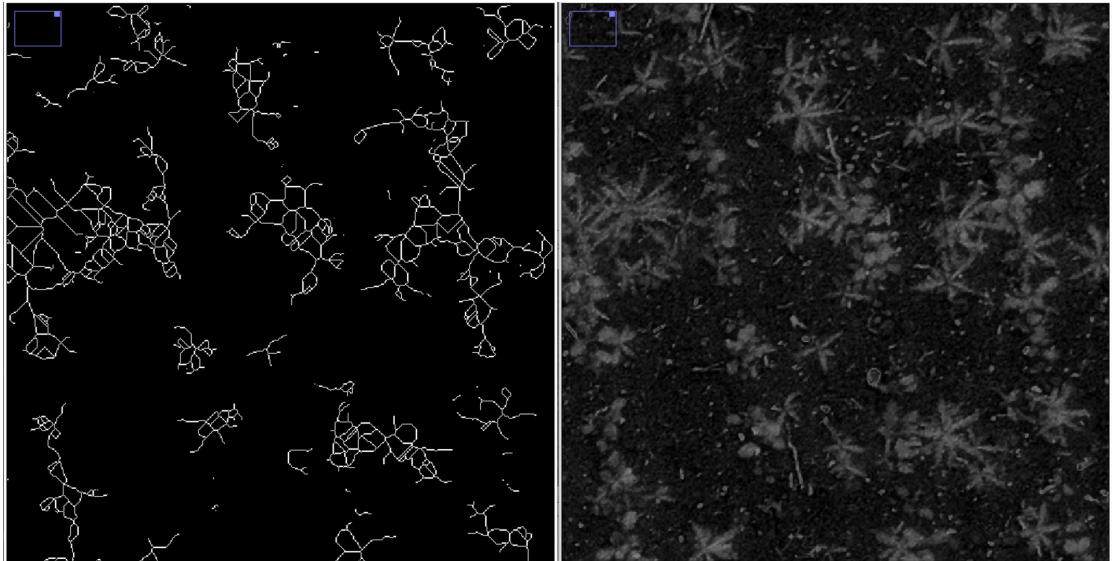


Figure 3: A gauche : une partie de l'image squelettisée, à droite : l'image correspondante traitée par ExG

repérer les endroits où se trouvent des formes similaires. Cette dernière méthode était également peu robuste à cause de la grande diversité de formes et de tailles des cires. Face aux difficultés que rencontrent les méthodes classiques d'analyse d'image pour reconnaître des formes/objets, nous nous sommes tournés vers le deep learning.

3.3 Découpage des images

Comme décrit ci-dessus les images sont découpées en sous images pour pouvoir être fournies en entrée du modèle. Différentes échelles de détection d'une cirse ont été discutées avec l'INRAE (cf. Figure 18). En effet, certains cires semblent trop grands pour des sous-images de 50x50 pixels. Cependant augmenter la taille des sous



Sous image respectivement de taille 50,100 et 200 pixels

Figure 4: Différentes échelles de sous-images discutées avec l'INRAE

images diminuera aussi la résolution des résultats, ainsi que le nombre d'exemple fourni au modèle. On souhaite que la plus petite zone où nous pourrons dire si on détecte ou non des cirses sera de la taille de l'imagette. Les photos du drone étant toutes au format 3000x4000 pixels, c'est l'échelle 100x100 pixels que nous avons retenue car elle correspond à la taille d'un cirse en entier en moyenne sur l'image : en prenant une taille plus petite, les cirses auraient été coupés pour la plupart des sous images.

Nous réalisons ce découpage en python grâce à un programme qui prend en entrée l'image entière en retourne en sortie un dossier contenant toutes ses sous-images (cf. Figure 5).



Figure 5: Exemple de découpage d'une portion d'image

3.4 Annotation manuelle des imagettes

Ensuite, pour réaliser l'annotation des images, nous avons développé un outil permettant d'annoter de manière rapide et fluide un grand nombre d'images. Pour cela nous utilisons tkinter, une bibliothèque permettant de créer des interfaces graphiques

sous python. Nous avons à ce jour annoté 4 images différentes, sélectionnées vis à vis de leur représentabilité du jeu de données, ce qui représente 4800 exemples.



Figure 6: Les 4 images annotées



Figure 7: Application d'annotation d'image

3.5 Modèle de machine learning pour la classification des images : CNN

D'après la littérature, l'approche de machine learning la plus efficace pour la classification d'images semble être les réseaux de neurones profonds et notamment les réseaux de neurones à convolution.

La particularité des CNN est qu'ils comportent des filtres de convolution. Ces filtres parcourent l'image et réalisent pour chaque pixel une opération de convolution à l'aide de leur matrice caractéristique. Ces filtres donnent en sortie une nouvelle valeur pour chaque pixel. Cela permet de faire ressortir certaines informations pertinentes de l'image d'entrée (comme la détection des contours des objets de l'image par exemple). Le nombre de pixels de déplacement du filtre de convolution dans les directions horizontale et verticale est réglé par le paramètre stride. Si le stride est égale à 1 la sortie du filtre est la même dimension que l'entrée, plus il est grand plus on réduit la dimension de l'image obtenue en sortie du filtre. Il existe différentes architectures, DenseNet décrite dans la partie bibliographie et ResNet décrite ci-après sont des architectures résiduelles (ce qui signifie que certaines couches peuvent être ignorées lors de l'apprentissage du modèle).

3.5.1 Architecture choisie : ResNet

ResNet (Residual Neural Network) est un type de réseau de neurones profond, apparu en 2015 et qui vise à résoudre le problème du gradient-vanishing/exploding au-delà d'un certain nombre de couches de neurones artificielles. Le gradient-vanishing est un problème qui survient lors de la phase d'apprentissage d'un réseau de neurones profond. Le gradient se rapproche parfois rapidement de 0 dans les couches les plus profondes. Le gradient exploding quand à lui est dû au fait que le gradient des poids des couches profondes augmente exponentiellement. Il en résulte alors une mauvaise classification, un ralentissement du temps d'apprentissage voire l'impossibilité de converger vers une solution optimale.

Le principe d'une architecture résiduelle comme ResNet est qu'elle utilise des connexions résiduelles pour faciliter la propagation des informations à travers les couches du réseau. Les connexions résiduelles permettent à une partie de l'entrée d'une couche de passer directement à la sortie de cette couche, sans être modifiée par les transformations effectuées par la couche elle-même. Ainsi, les informations importantes sont conservées, même dans les couches les plus profondes du réseau.

3.5.2 Les différentes versions

Il existe actuellement différentes versions de ResNet qui se caractérisent par un nombre de couches plus ou moins élevé et pouvant réaliser un certain nombre de tâches plus ou moins complexes. Les performances de ce type de réseau augmentent fortement avec le nombre de couches. Toutefois, il en va de même avec le coût de l'apprentissage, aussi bien en termes de temps de calcul que de mémoire.

Au vu de la puissance limitée du matériel informatique que nous avons à disposition et de la simplicité de la tâche à effectuer, nous prévoyons d'utiliser ResNet18.

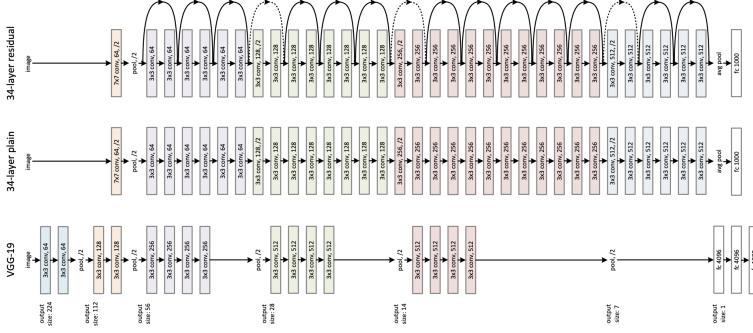


Figure 8: Schéma explicatif d'un ResNet comparé à un réseau fully-connected. Crédit K. HE et all 2015

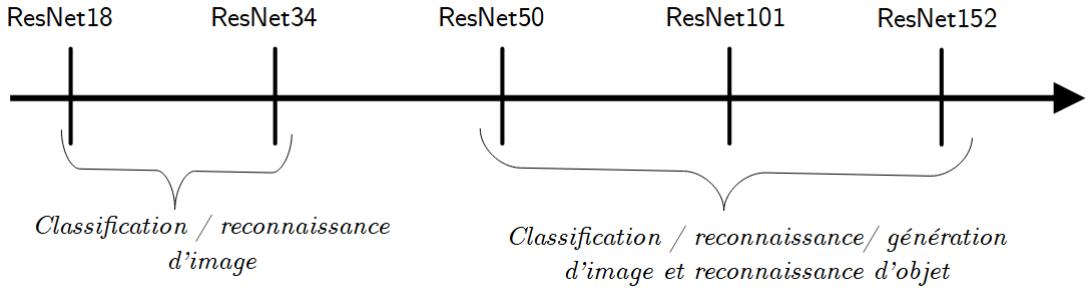


Figure 9: Les différentes versions de ResNet classées en fonction de la performance et de la complexité de la tâche à effectuer

3.5.3 Stratégies d'apprentissages

Toujours dans l'objectif de pallier aux limites des capacités de nos ordinateurs personnels, nous ne prévoyons pas de mettre à jour l'ensemble des paramètres des neurones artificiels qui composent le réseau de neurones. Nous prévoyons dans un premier temps de n'entraîner que le neurone de la dernière couche (neurone de sortie) et d'augmenter progressivement le nombre de couches pour lesquelles il faudrait actualiser les paramètres.

Une fois que nous aurons obtenu un modèle avec des performances acceptables, nous éprouverons la robustesse du modèle aux variations. C'est-à-dire que nous nous assurerons que le modèle prenne bien en compte la forme caractéristique des cires pour faire la classification. Cette robustesse nous permettra de nous affranchir des paramètres exacts des exemples d'apprentissage (luminosité, appareil photo utilisé, etc). Si nous estimons que le modèle obtenu n'est pas assez robuste aux variations, nous prévoyons de faire de l'augmentation de données voire d'augmenter le set d'apprentissage afin de mettre à jour les paramètres.

3.6 Le clustering pour l'identification des cirsés issus d'une reproduction clonale ou sexuelle

Une fois que nous aurons réussi à détecter les cirsés ou les zones contenant des cirsés via des bounding-box, nous décelerons alors les individus issus d'une reproduction clonale ou sexuelle. Pour faire cela, nous partons du principe (confirmé par les experts de l'INRAE) que les individus issus d'une reproduction clonale auront tendance à être beaucoup plus proche les uns des autres tandis que les individus issus de semences (déjà présents dans le sol, amenés par le vent etc) auront tendance à avoir une répartition beaucoup plus hétérogène sur le terrain? Cette répartition hétérogène se caractérise par des cirsés plus isolés des autres. Des observations confortant ces hypothèses ont d'ailleurs déjà été faites par l'ancien stagiaire qui travaillait sur la même problématique.

Afin d'identifier les groupes d'individus issus d'une même reproduction clonale, nous prévoyons d'utiliser un clustering par densité, plus précisément un DBSCAN. Cette méthode contrairement aux clusterings par k-mean ou ascendance hiérarchique permet de trouver des clusters sans a priori sur la forme. De plus, cette technique gère assez bien les données aberrantes (qui peuvent être importantes étant donné l'abondance de cirsés issus de graines). Il s'agira donc pour chaque grande image de représenter en 2D (hauteur, largeur) les coordonnées du centre de gravité de chaque sous-image. Ensuite nous déterminerons une distance minimale ϵ et a un nombre minimum de points, tel qu'un cluster (un groupe issu de la même division clonal clonale) se définisse comme étant un ensemble de points pour lesquels dans leur $\epsilon - voisinage$ au minimum a points. Ce type de clustering permet d'identifier 3 types de points :

- Les points du « cœur » qui respectent à la fois la contrainte de minimum a points dans son $\epsilon - voisinage$. A priori des cirsés issus de la même multiplication clonale.
- Les « bordures » des points rattachés à un point « cœur » dans son $\epsilon - voisinage$.
- Les « aberrants » qui ne répondent à aucun des critères. Les cirsés seront alors issus a priori de graines.

4 Résultats

4.1 Développement de l'approche par réseau de neurone à convolution

Nous développons maintenant l'approche par CNN. Nous utiliserons les images brutes, les images traitées par excess green et squelettisées pour voir si la prise en compte de ces différentes images nous permettrait d'améliorer les performances du réseau. Deux images annotées manuellement ont été choisies pour faire de l'inférence, venant ou non d'un autre série de photo de drône. La première image est issue du même set d'image que celles utilisées pour obtenir les sous-images qui ont servi à l'apprentissage, cette première image possédait également les mêmes caractéristiques

que le set d'entraînement, en termes de luminosité et de morphologie des cirsées. La deuxième image, quand à elle, provient d'une deuxième série de photo prise le 2 février 2023. Ce dernier jeu de donnée se différenciait par la luminosité ainsi que par la morphologie des cirsées (des feuilles beaucoup plus claires et étroites au lieu de feuilles plus larges et plus visibles sur les photos). Cette différence morphologique s'explique par un état plus avancé de la croissance, ainsi que par une période plus froide, qui rétrécit la taille des feuilles à cause du gel.

4.1.1 Resnet18 sur les images brutes, excess green et squelettisées sans data augmentation

Après entraînement du modèle, nous obtenons les performances maximales sur les images originales avec une balanced accuracy de 0.91, un taux de vrai positif de 0.86, ainsi qu'un taux de vrai négatif de 0.96 sur le set de test (cf. Figure 17). Les performances des réseaux de neurones entraînés sur les images Excess green et les images squelettisées étaient globalement moins bonnes, ayant tous les deux une balanced accuracy d'environ 0.8 (cf. Figure 10). En regardant les courbes ROC on constate que les classifications à partir des images Excess Green et des images squelettisées sont très décevantes puisque le modèle ne semble pas mieux faire que le hasard (cf. Figure 11).

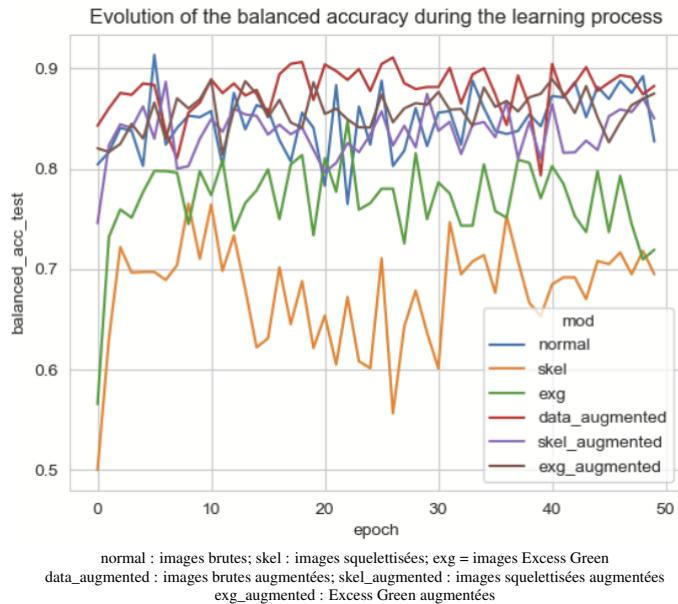
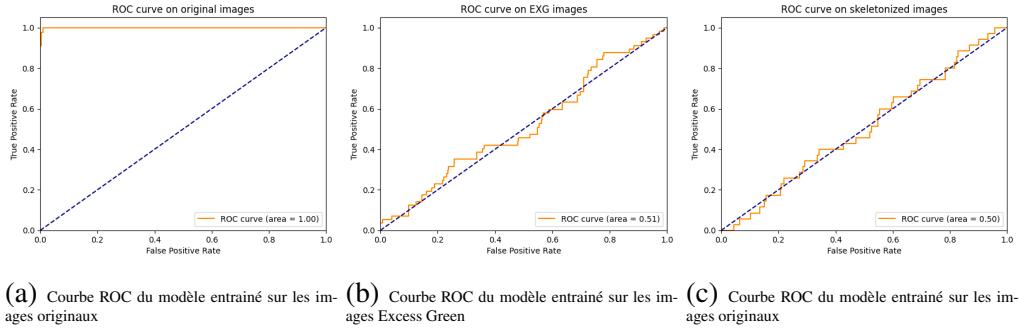


Figure 10: Evolution des performances des différents modèles lors de la phase d'apprentissage

4.1.2 Interprétabilité du modèle

Afin de vérifier la pertinence des classifications obtenues, nous avons générées une carte de saillance sur les sous-images de chaque set de validation. Globalement, nous constatons que pour la classe 0, à savoir absence de cirsées, la carte de saillance indique des pixels sans logique apparente, tout du moins pour l'œil humain. Pour la classe 1, c'est-à-dire présence de cirsées, la présence de cirsées correspond systématiquement



(a) Courbe ROC du modèle entraîné sur les images originales (b) Courbe ROC du modèle entraîné sur les images Excess Green (c) Courbe ROC du modèle entraîné sur les images originaux

Figure 11: Courbes ROC des modèles entraînées sans augmentation de données

à une mise en évidence de la zone qui correspond au centre de la rosette d'une cirse. Toutefois, même lorsqu'il y a plus d'une cirse sur la sous-image, la carte de saillance semble toujours indiquer le centre d'une seule rosette (cf. Figure 12).

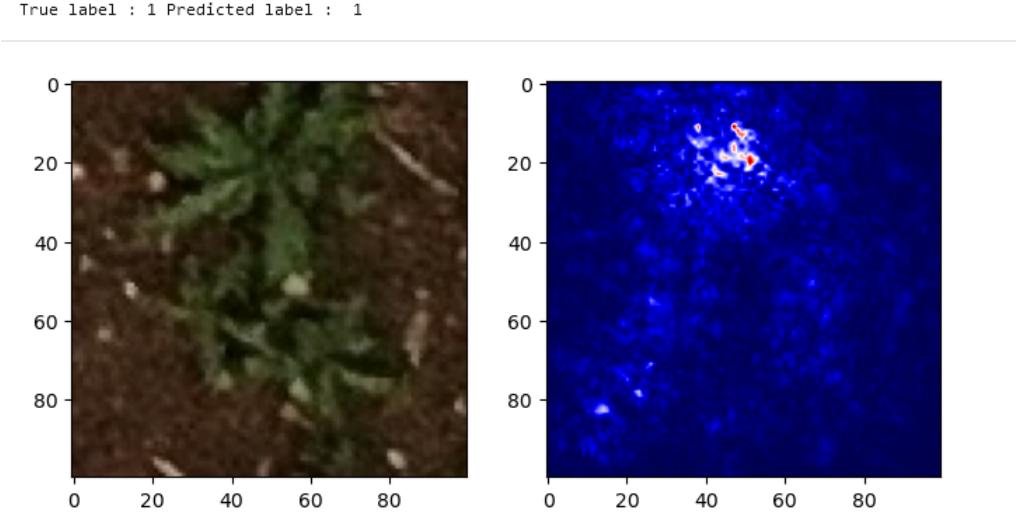


Figure 12: Saillance dans le cas d'un exemple positif

4.1.3 Augmentation des données

Problèmes de distribution biaisée des données et robustesse du modèle

Malgré de bonne performance et un bon apprentissage de la forme des cirsées par le réseau, les performances pourraient encore être améliorées. En effet le tableau ci-dessous indique qu'il y a un déséquilibre des classes. On voit que la classe majoritaire (étiqueté 0) représente 90 pourcent des effectifs, tandis que la classe minoritaire (étiqueté 1) ne représente que 10 pourcent.

Cela pose un problème car le modèle risque de favoriser une classe plus qu'une autre dans ses prédictions, étant donné qu'elle est plus représentée dans le jeu de données. Les éléments de la classe minoritaire peuvent être considérés comme des points aberrants.

Jeux de données	Examples positifs (1)	Examples négatifs (0)	Proportion positifs
Original	351	2529	0.121875
Original augmenté	1404	2529	0.356980

Table 1: Distribution des exemples dans les jeux de données

par le modèle. Nous souhaitons d'une part pallier à ce problème de biais des distribution des données mais également améliorer la robustesse du modèle à des perturbations telles que le bruit ou les occlusions. Nous choisissons donc de faire de la data augmentation, c'est à dire générer de nouvelles images à partir des sous images existantes.

Nous espérons ainsi réduire le biais en générant de nouvelles données qui représentent les cires en plus grande quantité d'une part et d'autre part améliorer la capacité du modèle à généraliser la reconnaissance des cires.

Rotation et application d'un bruit Gaussien

Pour augmenter le jeu de données nous effectuons pour chaque sous images positives 3 rotation à 90° . Nous augmentons ainsi le jeu de données initial par 4. De plus, nous ajoutons un bruit gaussien sur chacune des sous-images pour améliorer la capacité de généralisation du modèle. Un bruit gaussien est un type de bruit aléatoire qui peut être ajouté à une image pour simuler les variations et les perturbations présentes dans les images du monde réel. C'est donc ce type de bruit que nous choisissons pour augmenter notre jeu de données. Les pixels ajoutés suivent une distribution normale de moyenne 0 et d'écart-type 0.001.

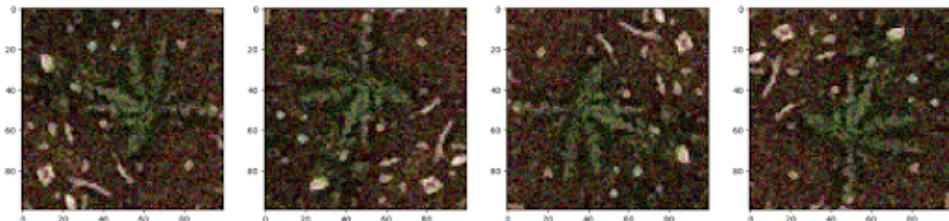
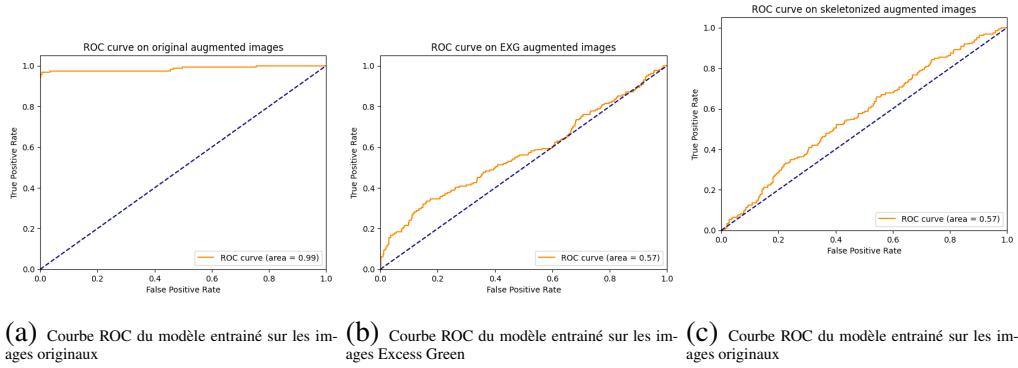


Figure 13: Transformation d'une seule sous-image du jeu de données: rotations et ajout de bruit

4.1.4 Resnet18 sur les images brutes, excess green et squelettisées avec data augmentation

D'un point de vue global, notre stratégie d'augmentation des données ne s'est pas avérée concluante puisque les performances sur les images originales augmentées sont à peine supérieur aux résultats obtenus sans augmentation. Comme les courbes ROC peuvent l'attester, l'augmentation des performances est beaucoup plus perceptible sur les images squelettisées et Excess Green. Toutefois, les modèles obtenus ne permettent de faire des prédictions plus satisfaisantes que le hasard (cf. Firgure 14, Figure 14a, Figure 14b, Figure ??).

Nous nous intéressons maintenant à un moyen de combiner les prédictions de ces 3 réseaux, entraînés respectivement que sur images excess green, squelettisées ou brutes.



(a) Courbe ROC du modèle entrainé sur les images originaux
 (b) Courbe ROC du modèle entrainé sur les images Excess Green
 (c) Courbe ROC du modèle entrainé sur les images originaux

Figure 14: Courbes ROC des modèles entraînés avec augmentation de données

Nous voulons voir si les prédictions sont meilleures par rapport à celles sur images brutes.

4.1.5 Combinaison des prédictions des 3 modèles

Vote majoritaire Afin de combiner les préditions des 3 modèles nous regardons pour chaque sous-image l'étiquette prédictive pour chaque modèle. Dans le cas du vote majoritaire, si la somme des prédictions de chaque modèle pour une sous-image donnée est supérieur à 2 alors on affecte l'étiquette 1 à cette sous image sinon 0.

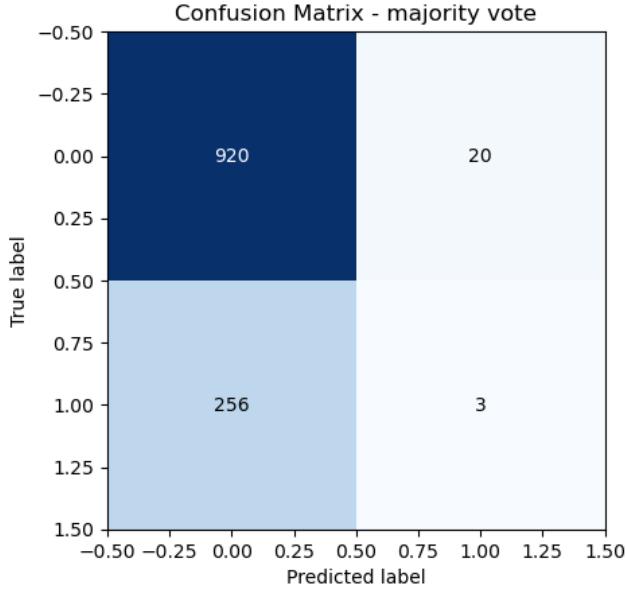


Figure 15: Performances du vote majoritaire

Nous lisons 920 VN, 20 FP, 256 FN et 3 VP. Seul 3 cirsés sont détectés par le vote majoritaire alors que 256 autres cirsés sont présents. Lorsque nous regardons les prédictions de chacun des modèles nous apercevons que le Resnet18 entraîné sur images squelettisées ne semble détecter aucun cirsé. Nous essayons donc de réaliser maintenant un vote à seule voix pour tenter de combiner ces 3 prédictions.

Vote à une seule voix Dans le cas du vote à une seule voix, lorsque la somme des

prédictions de chaque modèle pour une sous-image donnée est supérieur à 1, alors nous affectons l'étiquette 1 à cette sous image sinon 0.

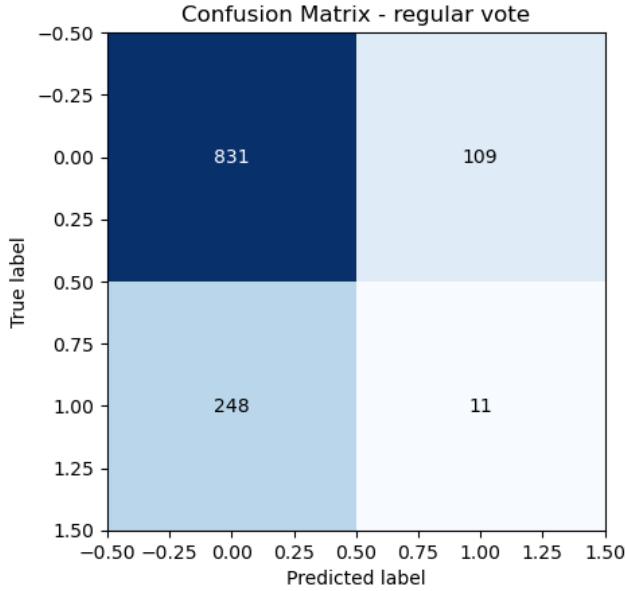


Figure 16: Performances du vote à une voix

Nous lisons 831 VN, 109 FN, 248 FN et 11 VP. Seulement 11 cires ont été détectés cette fois. Il reste encore 248 cires qui ne sont pas détectés par ce vote. Ces résultats sont peu satisfaisants. Nous concluons donc que cette approche n'est pas pertinante.

4.1.6 Inférence

Le réseau de neurone entraînée sur l'image issue de la première série de photo présentait des performances similaires à celles obtenues sur le set de test. C'est-à-dire que parmi les zones détectés comme étant négatifs, le taux de faux négatifs était inférieur à 5%. Toutefois, sur l'image issue de la deuxième série de photo les performances étaient loin d'être satisfaisantes : plus de la moitié des zones qui contenaient des cires n'ont pas pu être identifiés correctement par notre algorithme.

5 Limites de l'approche et perspectives

Bien que les résultats soient encourageants, les objectifs du projet n'ont pour la plupart pas pu être remplis. En effet, avec la quantité d'images et le temps à disposition, nous ne sommes pas parvenus à isoler chaque cirse sur une photo. La technique par segmentation d'image que nous avons utilisée afin d'isoler les zones de 100 * 100 pixels qui contiennent des cires s'est révélé assez pertinente sur des images qui présentent des caractéristiques similaires au set d'entraînement et de test. Toutefois, nous n'avons pas été en mesure de généraliser la méthode sur des images qui présentent des caractéristiques différentes. Les résultats obtenus en inférence se limitent à uniquement 2 images et doivent être pris avec une certaine précaution. Il aurait fallu évaluer les différents réseaux sur beaucoup plus d'images. Cependant, le temps d'annotation nécess-

saire aurait été beaucoup plus important. Il aurait été également beaucoup plus pertinent d'utiliser un seul et unique réseau de neurones pour faire une classification à partir des 3 types d'images (normal, squelettisée et Excess green), afin de prendre en compte une interaction potentielle dans la classification. Afin que la méthode obtenue soit beaucoup plus généralisable, il serait intéressant de revoir notre stratégie de prétraitement, notamment afin de limiter l'effet de la luminosité sur les performances. Lors de la phase d'entraînement du, il faudrait également veiller à introduire davantage de variabilité morphologique des cirsés dans les jeux de données.

6 Annexe

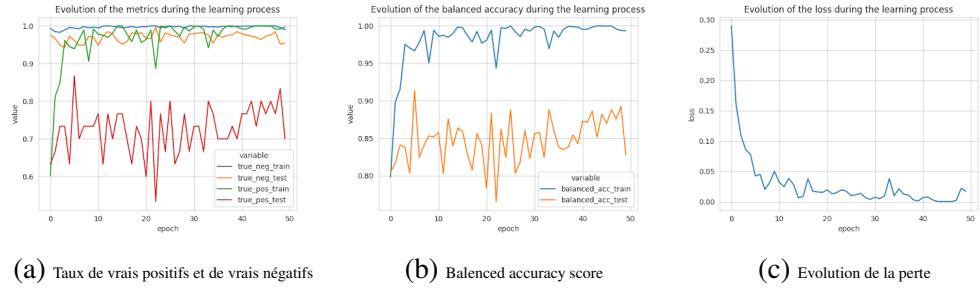


Figure 17: Résultat de Resnet18 sur des images brutes

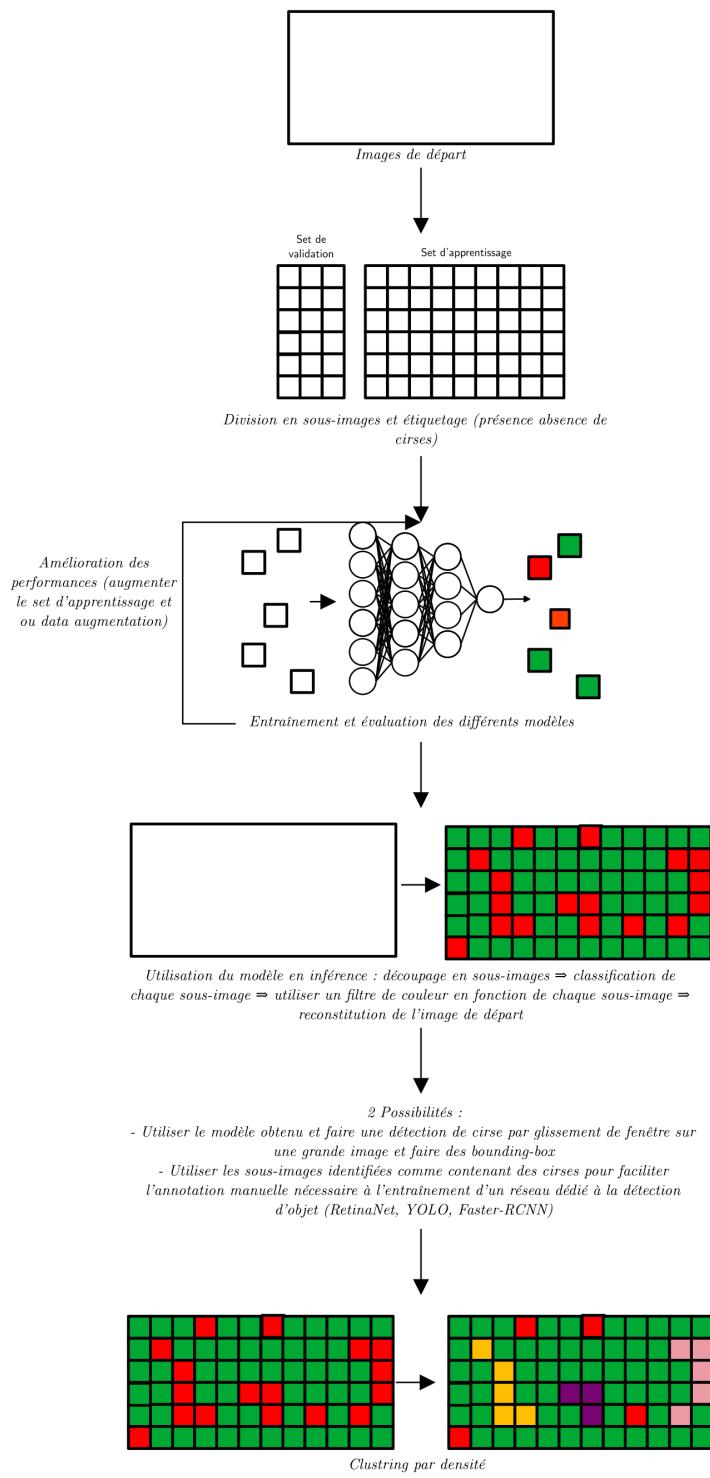


Figure 18: Schéma de synthèse des approches envisagées en apprentissage

7 Bibliographie

Dr. Brian Tuomanen - Hands-On GPU Programming with Python and CUDA Explore
 Barbosa, B. D. S., et al. RGB Vegetation Indices Applied to Grass Monitoring : A

Qualitative Analysis. 2019, p. 675.9Kb, <https://doi.org/10.15159/AR.19.119>.

Esposito, Marco, et al. “Drone and Sensor Technology for Sustainable Weed Management: A Review.” *Chemical and Biological Technologies in Agriculture*, vol. 8, no. 1, 2021, p. 18, <https://doi.org/10.1186/s40538-021-00217-8>.

HarryChen1995, Weed_detections : Weed Detection.

https://github.com/HarryChen1995/weed_detections. Accessed 6 Dec. 2022.

Hu, Kun, et al. Deep Learning Techniques for In-Crop Weed Identification: A Review. arXiv, 27 Mar. 2021, <http://arxiv.org/abs/2103.14872>.

Kamilaris, A., and F. X. Prenafeta-Boldú. “A Review of the Use of Convolutional Neural Networks in Agriculture.” *The Journal of Agricultural Science*, vol. 156, no. 3, Apr. 2018, pp. 312–22, <https://doi.org/10.1017/S0021859618000436>.

Kazmi, Wajahat, et al. “Detecting Creeping Thistle in Sugar Beet Fields Using Vegetation Indices.” *Computers and Electronics in Agriculture*, vol. 112, 2015, pp. 10–19, <https://doi.org/10.1016/j.compag.2015.01.008>.

Mirik, Mustafa, et al. “Remote Distinction of A Noxious Weed (Musk Thistle: *Carduus Nutans*) Using Airborne Hyperspectral Imagery and the Support Vector Machine Classifier.” *Remote Sensing*, vol. 5, no. 2, Jan. 2013, pp. 612–30, <https://doi.org/10.3390/rs5020612>.

Rasmussen, J., et al. “Pre-Harvest Weed Mapping of *Cirsium Arvense* in Wheat and Barley with off-the-Shelf UAVs.” *Precision Agriculture*, vol. 20, no. 5, 2019, pp. 983–99, <https://doi.org/10.1007/s11119-018-09625-7>.

Rosebrock, Adrian. “Turning Any CNN Image Classifier into an Object Detector with Keras, TensorFlow, and OpenCV.” *PyImageSearch*, 22 June 2020, <https://pyimagesearch.com/2020/06/22/turning-any-cnn-image-classifier-into-an-object-detector-with-keras-tensorflow-and-opencv/>.

Sai Priya, Anupuri, et al. “Weed Detection Using Machine Learning.” *International Journal of Advance Research, Ideas and Innovations in Technology*, vol. Volume 7, no. Issue 4-V7I4-1255, 2021, p. 4.

Sørensen, René A., et al. “Thistle Detection Using Convolutional Neural Networks.” *Neural Networks*, no. 75, 2017, p. 16.

Urmashov, Baydaulet, et al. “DEVELOPMENT OF A WEED DETECTION SYSTEM USING MACHINE LEARNING AND NEURAL NETWORK ALGORITHMS.” *Eastern-European Journal of Enterprise Technologies*, 2021, p. 16, <https://doi.org/10.15587/1729-4061.2021.246706>.