

*IODAA - De l'InfOrmation à la Décision par l'Analyse et  
l'Apprentissage*

*Projet Fil Rouge - Rendu de mi-projet*

---

**Dynamique des cirsés dans le paysage  
agricole et périurbain**

---

*Auteurs :*

Joseph Allyndrée  
Norat Picaut  
Amine Kabeche  
Delpierot Augustin

*Encadrant :*

Adrienne Ressayre

*github : [https://github.com/J-ally/PFR\\_Cirsés\\_2022](https://github.com/J-ally/PFR_Cirsés_2022)*

January 16, 2023

# Contents

<b>1</b>	<b>Introduction</b>	<b>2</b>
<b>2</b>	<b>Besoin de l'INRAE et problématique</b>	<b>2</b>
<b>3</b>	<b>Pistes explorées et résultats préliminaires</b>	<b>3</b>
3.1	Bibliographie . . . . .	3
3.2	Utilisations de méthodes d'analyse d'image "classiques" . . . . .	4
3.3	Découpage des images . . . . .	6
3.4	Annotation manuelle des imagettes . . . . .	7
3.5	Modèle de machine learning pour la classification des images : CNN . .	8
3.5.1	Architecture choisi : ResNet . . . . .	8
3.5.2	Les différentes versions . . . . .	9
3.5.3	Stratégies d'apprentissages . . . . .	9
3.6	Le clustering pour l'identification des cirsés issus d'une reproduction clonale ou sexuelle . . . . .	9
<b>4</b>	<b>Conclusion</b>	<b>11</b>
<b>5</b>	<b>Bibliographie actuelle</b>	<b>12</b>

# 1 Introduction

Les cires sont des plantes herbacées, bisannuelles ou vivaces, appartenant à la famille des Astéracées (ou Composées) et au genre *Cirsium*. *Cirsium arvense*, connu sous le nom de Chardon des champs ou Cirse des champs, est une espèce très commune en Europe. C'est une adventice de la plupart des cultures et des prairies. Il se multiplie rapidement par ses nombreuses graines qui, grâce à leurs aigrettes, peuvent être disséminées à grande distance.

Les cires sont donc capables de deux types de reproduction différentes :

- La reproduction sexuée, qui implique le mélange des chromosomes d'un mâle et d'une femelle pour former un nouvel individu qui est une combinaison des caractéristiques héritées des parents. Cette reproduction engendre les graines qui seront ensuite disséminées de différentes manières : transportées par les animaux (zoochorie), par le vent (anémochorie), et enfin une dissémination par l'eau est également possible (hydrochorie).
- La reproduction asexuée est aussi appelée reproduction végétative. Ce type de reproduction implique l'absence de mélange de chromosomes venant des parents et l'individu produit est génétiquement identique au seul l'individu parent (on parle alors de clone). Cette multiplication végétative se passe pour le cirse par les racines. On en observe ainsi deux types principaux : des racines ligneuses et verticales, mais également horizontales et profondes (50 à 100 cm de profondeur). Cette profondeur rend impossible un simple traitement par labour (labour allant seulement à une profondeur de 30cm).

Cette facilité à la reproduction et la difficulté de traitement le rend problématique pour les cultures. C'est ainsi la 3ème espèce la plus nuisible sur 24 pays européens, seule espèce résistante à 4 herbicides différents.

Notre projet se place donc au sein d'un projet déjà existant de compréhension de la dynamique des cires, comportant des approches multi sites et multidisciplinaires pour comprendre le fonctionnement de la métapopulation à l'échelle des paysages agricoles et évaluer l'impact des mesures de gestion

# 2 Besoin de l'INRAE et problématique

Pour mieux comprendre la dynamique des cires, des études de génétique des populations, associées à des analyses spatiales ont été lancées. Ces études ont plusieurs buts distincts: mesurer les proportions de multiplication végétative et de reproduction sexuée, étudier les liens entre habitats, évaluer l'impact des pratiques agricoles et de gestion vis-à-vis du cirse.

Ce projet concerne trois sites de l'INRAE : Dijon, Epoisse et Saclay. Chacun des ces sites dispose de parcelles d'essais avec des assolements différents (moutarde, colza, blé, maïs, etc.). Sur certaines de ces parcelles, la présence de cires a été observée à plus ou moins forte intensité (notamment les parcelles où les intrants chimiques ont été fortement réduits).

La problématique est donc de savoir comment détecter dans les différentes zones touchées et l'intensité de l'invasion par ces adventices sur ces zones ; et quelle est leur cinétique de propagation à l'échelle de l'ensemble des parcelles considérées.

## 3 Pistes explorées et résultats préliminaires

### 3.1 Bibliographie

L'approche choisie pour traiter ce problème de détection des cirsés à partir de l'image d'un champ est largement inspirée des travaux de Rasmussen et al (2019) et celui de A. Sørensen et al (2017). Rasmussen et al cherchent à détecter des cirsés à partir de photos de drones de champs de blé d'hiver et d'orge de printemps. Ils développent ainsi un outil semi-automatique appelé Thistle Tool basé exclusivement sur la discrimination des couleurs (les adventices, majoritairement des cirsés, apparaissent en vert et les cultures au stade pré-récolte donc sénecentes sont découlour paille). Les images sont divisées en patches de 1 m<sup>2</sup> quelle que soit l'altitude de vol et données en entrée de l'outil, qui réalise les étapes suivantes :

- Calcul de l'indice d'excès de vert noté ExG<sub>x,y</sub>, (Excess green) pour chaque coordonnée de pixel (x, y) de l'image. Cette indice représente l'intensité du vert de chaque pixel, il est calculé en calculant, pour chaque pixel (2G-R-B) avec G l'intensité de vert du pixel, R l'intensité de rouge, B l'intensité de bleu.
- Calcul d'un classifieur grâce à la TopMaxExG, utilisée faire le seuillage
  - Calcul de la TopMaxExG, c'est à dire valeur moyenne des p% de valeurs ExG les plus élevées dans chaque patch, p étant un paramètre. Si p=5 (valeur prise par défaut), alors les 5% des valeurs de ExG les plus élevées dans le patch sont utilisées pour calculer la valeur moyenne TopMaxExG du patch en question
  - Seuillage des patchq, c'est à dire séparation des objets d'intérêts (cirsés) du fond (culture et/ou terre). Le seuil de segmentation t est déterminé manuellement.
- Les patchs sont finalement classés en deux catégories: avec ou sans végétation verte.

Cette approche permet d'obtenir 92 à 97% de bonne classifications sur les images de vol allant de 10 à 50 m d'altitude. Ils observent que la hauteur de vol a peu d'impact sur l'accuracy. Toutefois le seuil de segmentation t (utilisée lors du seuillage des patchq) varie d'une campagne de vol à l'autre. Bien que performante, cette approche n'est pas totalement automatique et n'est pas utilisable lorsque la culture est encore à un stade immature.

Dans leur article datant de 2017, A. Sørensen et al cherchent à améliorer Thistle Tool en utilisant un réseau de neurones à convolution. L'objectif étant de pouvoir détecter les structures et les détails caractéristiques des patchs avec adventices. Le réseau utilisé

est un DenseNet, un réseau à convolution possédant une architecture de type résiduelle, c'est-à-dire que : l'input d'un bloc de filtres convolutionnel et redistribué à l'output de ce bloc. Le modèle apprend l'effet du bloc sur l'input c'est-à-dire qu'il apprend le résidu de chaque bloc (la différence entre l'output du bloc et l'input au départ du bloc). Dans le cas du DenseNet un bloc de filtre à convolution ajoute ses inputs à tous les blocs suivants. En donnant en entrée au modèle une imagette il renvoie la valeur associée à sa classe prédictive, et en lui donnant une grande image il renvoie un vecteur correspondant à probabilité d'appartenance à une des classes de chaque imagette qui compose la grande image.

Ils obtiennent d'aussi bonnes performances que Thistle Tool sur les deux types de cultures séparément ainsi que sur une sur de l'orge d'hiver, mais de meilleures performances sur les cultures combinées avec des images prises à 10m d'altitude. Les images prises à plus haute altitude sont de plus faibles résolution et donc plus difficiles à annoter correctement.

### 3.2 Utilisations de méthodes d'analyse d'image “classiques”

En nous inspirant du workflow de Thistle Tool, la première étape fut d'essayer d'isoler la verdure dans une photo du drone. Pour cela on utilise la métrique ExG (Excess Green) évoquée ci-dessus, qui donne les résultats suivants :

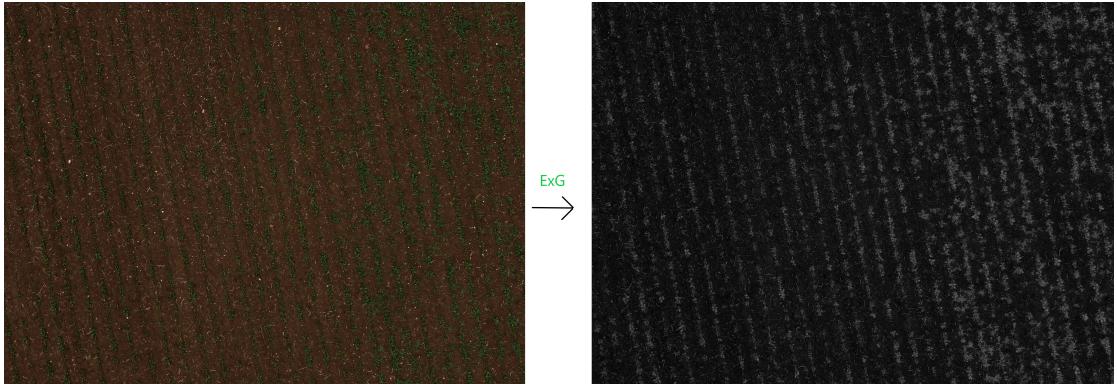


Figure 1: Passage de l'image d'origine à une image avec l'indice de végétation ExG.

On observe que la méthode ExG est très robuste pour détecter la verdure dans une photographie. Cependant on cherche à identifier les cires en particulier. A l'inverse de Thistle Tool qui utilisait des images de champs de blé jaunes, notre plante d'intérêt (la moutarde ici) a la même couleur (verte) que les cires. Ainsi, une sélection sur simple seuillage (cf. Figure 2) est insuffisant car il sélectionne aussi les plants de moutarde.

Nous devons donc essayer de repérer la forme caractéristiques des cires. Pour cela nous avons tout d'abord essayé des méthodes de squelettisation. La squelettisation est un procédé consistant à réduire chaque forme d'une image binarisée (comme la figure 2) à son squelette, i.e une structure fine d'un pixel et équidistante des bords de la forme. Cela permet d'analyser les formes des objets. On obtient le résultat suivant (cf. Figure 3).

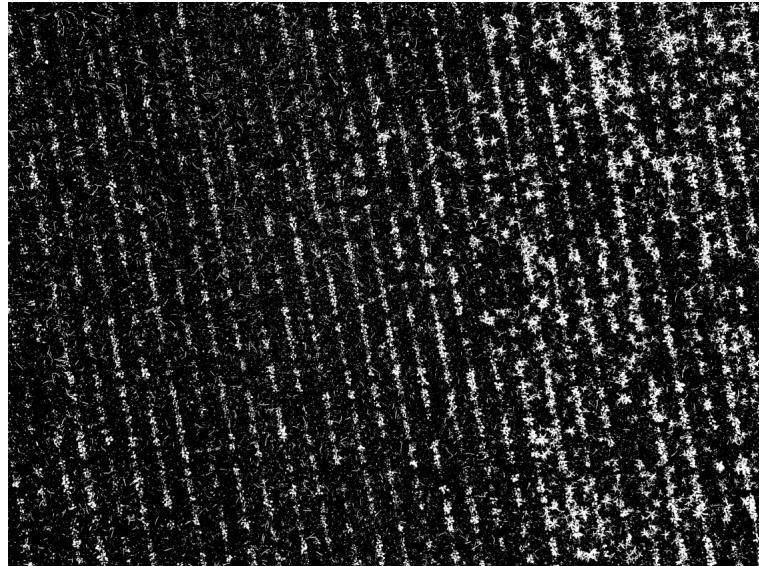


Figure 2: Résultat du seuillage de l'image en ExG par la méthode de Yen

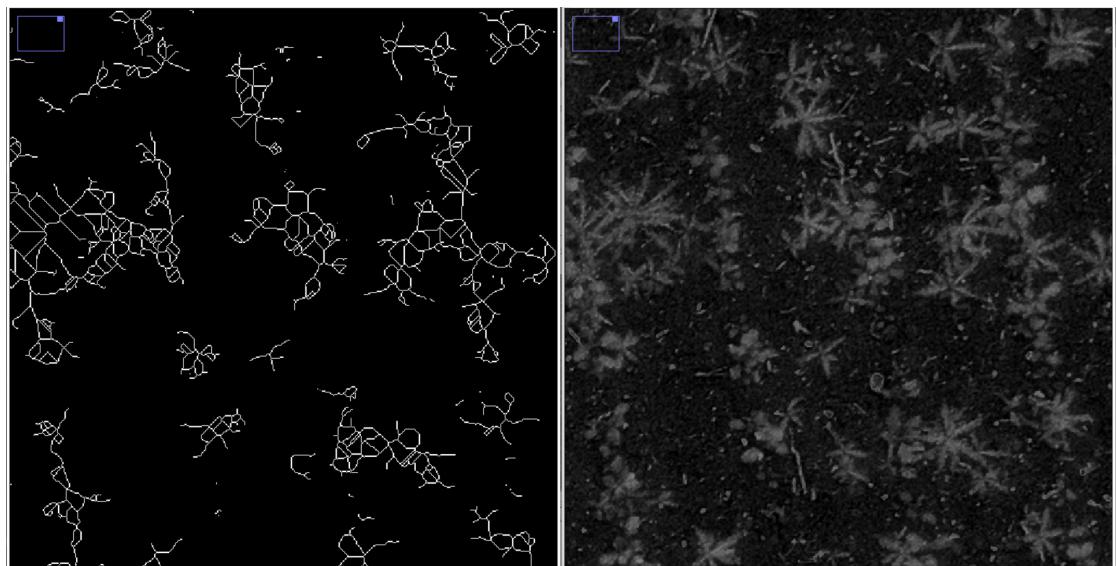


Figure 3: A gauche : une partie de l'image squelettisée, à droite : l'image correspondante traitée par ExG

On peut voir que la forme caractéristique en étoile des cires est mise en valeur dans l'image squelettisée. Cependant nous n'avons pas trouvé une façon automatique et robuste de pouvoir repérer cette forme pour l'instant. Nous avons essayé d'autres méthodes, comme convertir une forme de cirse en filtre de convolution pour repérer les endroits où se trouvent des formes similaires.

Cette méthode était aussi peu robuste à cause de la grande diversité de formes et de tailles des cires. Face aux difficultés que rencontrent les méthodes classiques d'analyse d'image pour reconnaître des formes/objets, nous nous tournons maintenant vers le deep learning.

### 3.3 Découpage des images



**Sous image respectivement de taille 50,100 et 200 pixels**

Figure 4: Différentes échelles de sous-images discutées avec l'INRAE

Comme décrit ci-dessus les images sont découpées en sous images pour pouvoir être fournies en entrée du modèle. Différentes échelles de détection d'une cirse ont été discutées avec l'INRAE (cf. Figure 10). En effet, certains cirsés semblent trop grands pour des sous-images de 50x50 pixels. Cependant augmenter la taille des sous images diminuera aussi la résolution des résultats. On souhaite que la plus petite zone où on pourra dire si oui ou non on détecte des cirsés sera de la taille de l'imagette. Les photos du drone étant toutes au format 3000x4000 pixels, c'est l'échelle 100x100 pixels qui a été retenue car elle correspond à la taille d'une cirse en entier en moyenne sur l'image. On réalise ce découpage en python grâce à un programme qui prend en entrée l'image entière en retourne en sortie un dossier contenant toutes ses sous-images (cf. Figure 5).



Figure 5: Exemple de découpage d'une portion d'image

### 3.4 Annotation manuelle des imagettes

Nous avons développé un outil d'annotation des images permettant d'annoter de manière rapide et fluide un grand nombre d'images. Pour cela nous utilisons tkinter, une bibliothèque permettant de créer des interfaces graphiques sous python. Nous avons à ce jour annoté 4 images différentes, sélectionnées vis à vis de leur représentabilité du jeu de données.

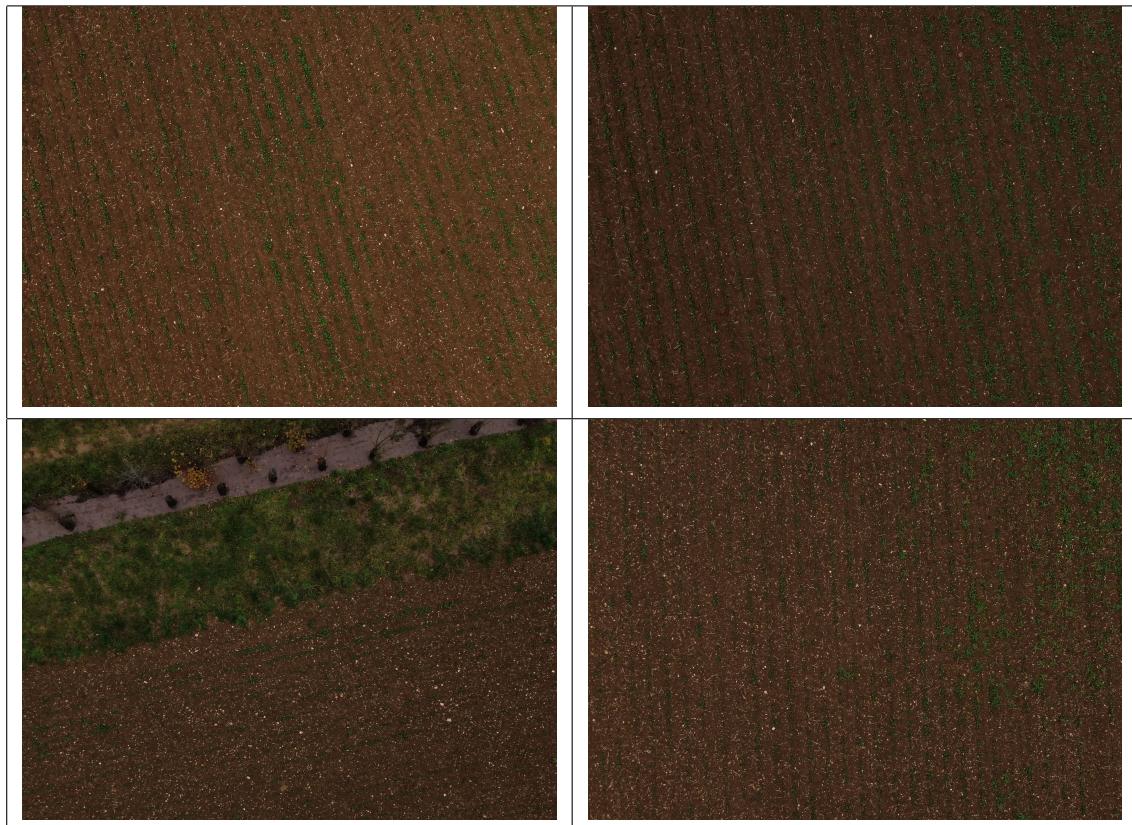


Figure 6: Les 4 images annotées



Figure 7: Application d'annotation d'image

## 3.5 Modèle de machine learning pour la classification des images : CNN

D'après la littérature, l'approche de machine learning la plus efficace pour la classification d'images semble être les réseaux de neurones et notamment les réseaux de neurones à convolution.

La particularité des CNN est qu'ils comportent des filtres de convolution. Un filtre à convolution est une matrice. Le filtre parcourt l'image et réalise pour chaque pixel une opération de convolution à l'aide de la matrice, ce qui donne en sortie du filtre une nouvelle valeur pour chaque pixel. Cela permet de faire ressortir certaines informations pertinentes de l'image d'entrée (comme la détection des contours des objets de l'image). Le nombre de pixels de déplacement du filtre de convolution dans les directions horizontale et verticale est réglé par le paramètre stride. Si le stride est égale à 1 la sortie du filtre est la même dimension que l'entrée, plus il est grand plus on réduit la dimension de l'image d'entrée en sortie du filtre.

### 3.5.1 Architecture choisi : ResNet

ResNet (residual neural network) est un type de réseau de neurones profond, apparu en 2015 et qui vise à résoudre le problème du gradient-vanishing/exploding au-delà d'un certain nombre de couches de neurones artificielles. Le gradient-vanishing est un problème qui survient lors de la phase d'apprentissage d'un réseau de neurones profond, se rapproche assez rapidement de 0 dans les couches les plus profondes. Le gradient exploding quant à lui est dû au fait que le gradient des poids des couches profondes augmente exponentiellement. Il en résulte alors une mauvaise classification, un ralentissement du temps d'apprentissage voire l'impossibilité de converger vers une solution optimale.

La particularité de ResNet est d'utiliser des raccourcis de connexions pour connecter les couches les plus proches de l'entrée aux couches les plus proches de la sortie, en sautant une ou plusieurs couches. Ainsi, l'information importante est conservée dans les couches les plus profondes du réseau.

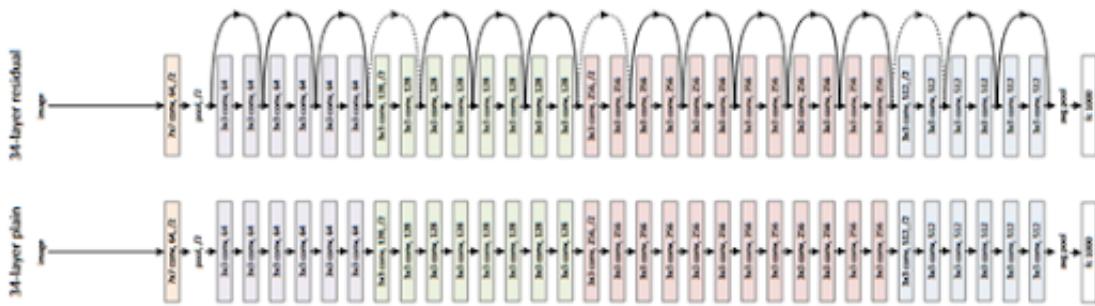


Figure 8: Schéma explicatif d'un ResNet comparé à un réseau fully-connected. Crédit K. HE et all 2015

### 3.5.2 Les différentes versions

Il existe actuellement différentes versions de ResNet qui se caractérisent par un nombre de couches plus ou moins élevé et pouvant réaliser un certain nombre de tâches plus ou moins complexes. Les performances de ce type de réseau augmentent fortement avec le nombre de couches. Toutefois, il en va de même avec le coût de l'apprentissage. Que ce soit en termes de temps de calcul et de mémoire.

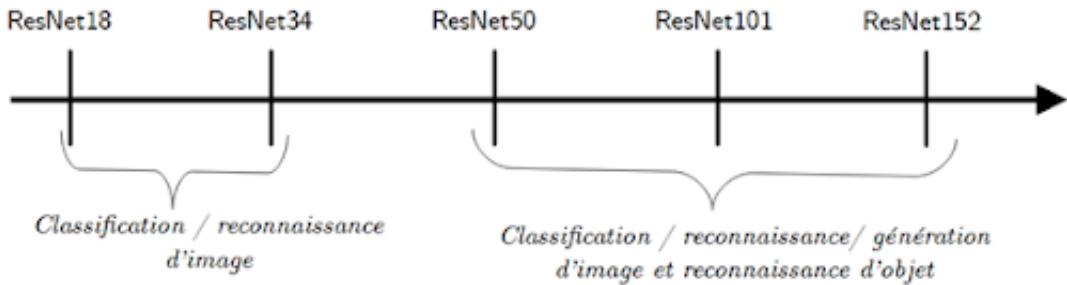


Figure 9: Les différentes versions de ResNet classées en fonction de la performance et de la complexité de la tâche à effectuer

Au vu de la puissance limitée du matériel informatique que nous avons à disposition et de la simplicité de la tâche à effectuer, nous prévoyons d'utiliser ResNet18 et potentiellement ResNet 34 si les résultats obtenus avec ce dernier ne sont pas probants.

### 3.5.3 Stratégies d'apprentissages

Toujours dans l'objectif de pallier aux limites des capacités de nos ordinateurs personnels, nous ne prévoyons pas de mettre à jour l'ensemble des paramètres des neurones artificiels qui composent le réseau de neurones artificiel. Nous prévoyons dans un premier temps de n'entraîner que le neurone de la dernière couche (neurone de sortie) et d'augmenter progressivement le nombre de couches pour lesquelles il faudrait actualiser les paramètres.

Une fois que nous aurons obtenu un modèle avec des performances acceptables, il nous faudra alors éprouver la robustesse du modèle aux variations. C'est-à-dire que nous devrons nous assurer que le modèle prenne bien en compte la forme caractéristique des cirsés pour faire la classification. Ce afin que le réseau mise en place fonctionne indépendamment de la luminosité, de l'appareil photo utilisé, etc. Si nous estimons que le modèle obtenu n'est pas assez robuste aux variations, nous prévoyons de faire de l'augmentation de données voir d'augmenter le set d'apprentissage afin de mettre à jour les paramètres.

## 3.6 Le clustering pour l'identification des cirsés issus d'une reproduction clonale ou sexuelle

Une fois que nous aurons plus ou moins réussi à détecter les cirsés ou les zones contenant des cirsés via des bounding-box, il nous faudra alors déceler les individus

issus d'une reproduction clonale ou sexuelle. Pour se faire nous partons du principe que les individus issus d'une reproduction clonale auront tendance à être beaucoup plus proche les uns des autres tandis que les individus issus de semences (déjà présents dans le sol, amenés par le vent etc) auront tendance à avoir une répartition beaucoup plus hétérogène sur le terrain et seront donc plus susceptibles d'être isolés des autres cirsés. Des observations confortant cette hypothèse ont d'ailleurs déjà été faites par l'ancien stagiaire qui travaillait sur la problématique des cirsés.

Afin d'identifier les groupes d'individus issus d'une même reproduction clonale, nous prévoyons d'utiliser un clustering par densité, plus précisément un DBSCAN. Cette méthode contrairement aux clusterings par k-mean ou ascendance hiérarchique permet de trouver des clusters sans a priori sur la forme et gère assez bien les cas donnés aberrantes (qui peuvent être importants étant donné l'abondance plus ou moins importante de cirsés issus de graines). Il s'agira donc pour chaque grande image de représenter en 2D (hauteur, largeur) les coordonnées du centre de gravité de chaque bounding-box. Il s'agira alors de déterminer une distance minimale  $\epsilon$  et  $a$  un nombre minimum de points, tel qu'un cluster (un groupe issu de la même division clonal clonale) se définisse comme étant un ensemble de points pour lesquels dans leur  $\epsilon - voisinage$  au minimum  $a$  points. Ce type de clustering permet d'identifier 3 types de points :

- Les points du « cœur » qui respectent à la fois la contrainte de minimum  $a$  points dans son  $\epsilon - voisinage$ . A priori des cirsés issus de la même multiplication clonal.
- Les « bordures » des points rattachés à un point « cœur » dans son  $\epsilon - voisinage$ .
- Les « aberrants » qui ne répondent à aucun des critères. Les cirsés sont issus a priori de graines.

## 4 Conclusion

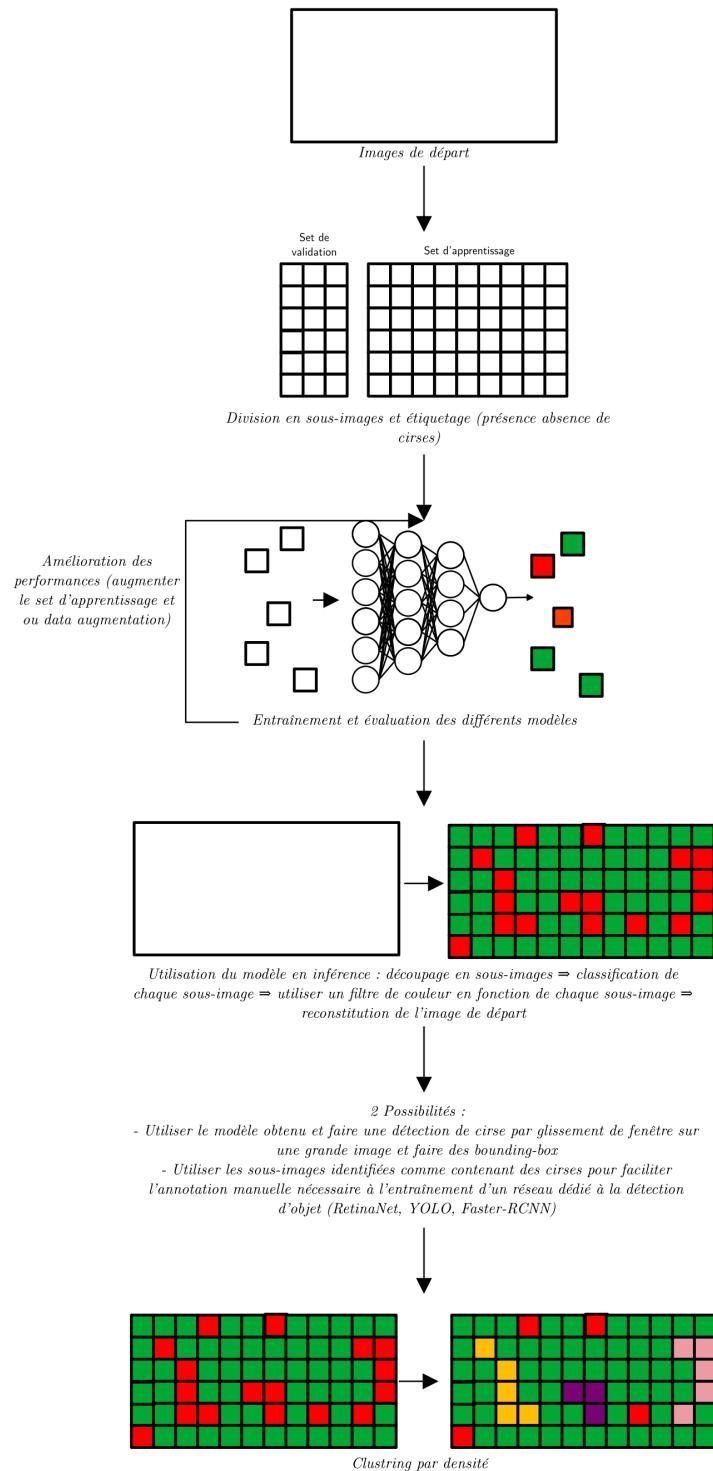


Figure 10: Schéma de synthèse des approches envisagées en apprentissage

## 5 Bibliographie actuelle

- Dr. Brian Tuomanen - Hands-On GPU Programming with Python and CUDA Explore
- Barbosa, B. D. S., et al. RGB Vegetation Indices Applied to Grass Monitoring : A Qualitative Analysis. 2019, p. 675.9Kb, <https://doi.org/10.15159/AR.19.119>.
- Esposito, Marco, et al. “Drone and Sensor Technology for Sustainable Weed Management: A Review.” Chemical and Biological Technologies in Agriculture, vol. 8, no. 1, 2021, p. 18, <https://doi.org/10.1186/s40538-021-00217-8>.
- HarryChen1995, Weed\_detections : Weed Detection.  
[https://github.com/HarryChen1995/weed\\_detections](https://github.com/HarryChen1995/weed_detections). Accessed 6 Dec. 2022.
- Hu, Kun, et al. Deep Learning Techniques for In-Crop Weed Identification: A Review. arXiv, 27 Mar. 2021, <http://arxiv.org/abs/2103.14872>.
- Kamilaris, A., and F. X. Prenafeta-Boldú. “A Review of the Use of Convolutional Neural Networks in Agriculture.” The Journal of Agricultural Science, vol. 156, no. 3, Apr. 2018, pp. 312–22, <https://doi.org/10.1017/S0021859618000436>.
- Kazmi, Wajahat, et al. “Detecting Creeping Thistle in Sugar Beet Fields Using Vegetation Indices.” Computers and Electronics in Agriculture, vol. 112, 2015, pp. 10–19, <https://doi.org/10.1016/j.compag.2015.01.008>.
- Mirik, Mustafa, et al. “Remote Distinction of A Noxious Weed (Musk Thistle: CarduusNutans) Using Airborne Hyperspectral Imagery and the Support Vector Machine Classifier.” Remote Sensing, vol. 5, no. 2, Jan. 2013, pp. 612–30, <https://doi.org/10.3390/rs5020612>.
- Rasmussen, J., et al. “Pre-Harvest Weed Mapping of Cirsium Arvense in Wheat and Barley with off-the-Shelf UAVs.” Precision Agriculture, vol. 20, no. 5, 2019, pp. 983–99, <https://doi.org/10.1007/s11119-018-09625-7>.
- Rosebrock, Adrian. “Turning Any CNN Image Classifier into an Object Detector with Keras, TensorFlow, and OpenCV.” PyImageSearch, 22 June 2020, <https://pyimagesearch.com/2020/06/22/turning-any-cnn-image-classifier-into-an-object-detector-with-keras-tensorflow-and-opencv/>.
- Sai Priya, Anupuri, et al. “Weed Detection Using Machine Learning.” International Journal of Advance Research, Ideas and Innovations in Technology, vol. Volume 7, no. Issue 4-V7I4-1255, 2021, p. 4.
- Sørensen, René A., et al. “Thistle Detection Using Convolutional Neural Networks.” Neural Networks, no. 75, 2017, p. 16.
- Urmashov, Baydaulet, et al. “DEVELOPMENT OF A WEED DETECTION SYSTEM USING MACHINE LEARNING AND NEURAL NETWORK ALGORITHMS.” Eastern-European Journal of Enterprise Technologies, 2021, p. 16, <https://doi.org/10.15587/1729-4061.2021.246706>.